




Strojové učení

5 Logistická regrese

- Logistická regrese
- Model hypotézy pro LogR
- Interpretace výsledků
- Rozhodovací hranice
- Cenová funkce pro LogR
- Klasifikace do více tříd
- Algoritmus One vs All





Logistická regrese

Regrese pro predikci diskretních hodnot

- predikovaná proměnná $y = h_{\Theta}(\mathbf{x})$ nabývá diskretních hodnot: buď 0 nebo 1 – **binomická** či **binární logistická regrese**, nebo 0 až K – **multinomická logistická regrese** (MNL) nebo také logistická regrese s vícekategoriální vysvětlovanou proměnnou, **tj. jedná se o klasifikační úlohu**
- predikovaná proměnná (čili modelovaná veličina) má tzv. **alternativní rozdělení p-sti** (*Bernoulli Distribution*) – jde o variantu binomického rozdělení $Bi(n, p)$, kde počet pokusů $n = 1$ a p je p-st úspěchu (čili proměnná nabyde hodnoty 1)
- **jeden z nejpopulárnějších a nejrozšířenějších učících se algoritmů**, řada dalších technik z oblasti UI a strojového učení je na ní založena





Logistická regrese

Příklady klasifikačních úloh

Binární logistická regrese –

$$y = h_{\Theta}(\mathbf{x}) \in \{0; 1\}$$

→ 0: **negativní třída**

→ 1: **pozitivní třída**

- **E-mail:** spam / ne-spam
- **Lékařská diagnostika nádorů:** zhoubný / nezhoubný
- **Bezpečnost (IS):** autentizovaný / neautentizovaný přístup

n -ární (multinomická) lineární regrese –

$$y = h_{\Theta}(\mathbf{x}) \in \mathbf{N} \cup \{0\}$$

- **Lékařská diagnostika:** angína / chřipka / rýmička / kašel / ...
např. existující systém DXplain (<http://dxplain.org/dxp/dxp.pl>)




Logistická regrese

Motivační příklad – tribodiagnostika

Vyměnit
součástku?

ANO



NE

Co se stane při aplikaci již známého aparátu **lineární regrese**?
Zkusme proložit data přímkou, tj. hypotéza $h_{\Theta}(x) = \Theta_0 + \Theta_1 x$



Logistická regrese

Motivační příklad – tribodiagnostika


Problém: Hypotéza v tomto tvaru předpovídá hodnoty mimo $\langle 0, 1 \rangle$

Vyměnit součástku?

ANO

→ vyměna součástky [0/1]

NE



Klasifikaci provedeme prahováním hypotézy $h_{\theta}(x)$ hodnotou 0,5:
 pro $h_{\theta}(x) \geq 0.5$: $y \leftarrow 1$; pro $h_{\theta}(x) < 0.5$: $y \leftarrow 0$



Logistická regrese

Motivační příklad – tribodiagnostika

Můžeme mít štěstí a bude to nějak fungovat, ale mnohem častěji to **fungovat nebude**, a to zejména proto, že:


- byť jsou data (odpovědi učitele) v trénovací množině pouze z množiny $\{0; 1\}$, algoritmus předpovídá spojité hodnoty na intervalu $(-\infty; \infty) \rightarrow$ nevíme, co dělat s hodnotami mimo interval $<0; 1>...$
- pro hodnoty $h_{\theta}(x) \in <0; 1>$ stanovíme práh na hodnotě 0.5 – to ale nemusí být správná hodnota prahu, prahem určená oddělující nadplocha neseparuje data z trénovací množiny správně podle pokynů učitele
- vyskytnou-li se v datech extrémní marginální hodnoty, pak takto navržený mechanismus klasifikace selže úplně (viz následující obr.)





Logistická regrese

Motivační příklad – tribodiagnostika





Logistická regrese

Vlastnosti

Klasifikační úloha: $y \in \{0; 1\}$

Lineární regrese: $y = h_{\Theta}(x) \in (-\infty; \infty)$

- omezení hypotézy na interval $<0; 1>$ je problematické $\rightarrow$ není jednoznačné, nelze algoritmem LR určit/natrénovat, je velmi citlivé na extrémní marginální hodnoty v trénovací množině, atd.

Logistická regrese: $y = h_{\Theta}(x) \in <0; 1>$

- ač se to z historických důvodů nazývá regrese, jedná se o **klasifikaci** (protože hypotéza logistické regrese predikuje z daného vstupu x pravděpodobnost, že $y = 1$)






Logistická regrese

Reprezentace hypotézy

Požadujeme $0 \leq h_{\Theta}(\mathbf{x}) \leq 1$,

tj. $h_{\Theta}(\mathbf{x}) = P(\Theta^T \mathbf{x})$

reálné
číslo



Hypotéza má tedy tvar:

$$h_{\Theta}(\mathbf{x}) = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$

– **sigmoida** je speciálním případem tzv. **logistické funkce** (*Logistic Function*) pro $a = 1$, $m = 0$, $n = 1$, $\tau = 1$

$$f(t; a, m, n, \tau) = a \frac{1 + me^{-t/\tau}}{1 + ne^{-t/\tau}}$$



Logistická regrese

Interpretace výsledků hypotézy

$h_{\Theta}(\mathbf{x})$ – odhad **pravděpodobnosti**, že modelovaná veličina nabude hodnoty 1 (tj. např. jev nastane), je-li vstupem vektor příznaků $\mathbf{x}$

Příklad: Při tribodiagnostice byla naměřena průměrná velikost částic kovu v oleji 3.27 μ – tzn. vstupem hypotézy bude

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ 3.27 \end{bmatrix}$$

nutné, aby to šlo zapsat maticově jako soustavu

$$h_{\Theta}(\mathbf{x}) = \frac{1}{1 + e^{-(\Theta_0 + \Theta_1 \cdot 3.27)}} = 0.79$$

Hypotéza říká, že při velikosti částic 3.27 μ je s **pravděpodobností 79% potřeba ložisko vyměnit.**



Logistická regrese

Statistická interpretace výsledků hypotézy

$h_{\Theta}(\mathbf{x})$ – pravděpodobnost, že $y = 1$ za podmínky $\mathbf{x}$, parametrizovaná Θ :

$$h_{\Theta}(\mathbf{x}) = P(y = 1 \mid \mathbf{x}; \Theta)$$

Z toho plynou některé zřejmé závěry:

$$P(y = 0 \mid \mathbf{x}; \Theta) + P(y = 1 \mid \mathbf{x}; \Theta) = 1, \text{ z čehož}$$

$$P(y = 0 \mid \mathbf{x}; \Theta) = 1 - P(y = 1 \mid \mathbf{x}; \Theta)$$

Tzn. v předchozím příkladu odhad pravděpodobnosti, že ložisko není třeba měnit, je $1 - 0.79 = 0.21$, tj. 21%



Logistická regrese

Chování modelu

Hypotéza $h_{\Theta}(\mathbf{x}) = P(\Theta^T \mathbf{x})$, kde

$$P(t) = \frac{1}{1 + e^{-t}}$$

Model predikuje:

„ $y = 1$ “ $\Leftrightarrow h_{\Theta}(\mathbf{x}) \geq 0.5$, tj.


$$P(t) \geq 0.5$$

$$\Theta^T \mathbf{x} \geq 0$$

„ $y = 0$ “ $\Leftrightarrow h_{\Theta}(\mathbf{x}) < 0.5$, tj.

$$P(t) < 0.5$$

$$\Theta^T \mathbf{x} < 0$$





Rozhodovací hranice (*Decision Boundary*)


Chování LR v obrazovém prostoru

$$h_{\Theta}(\mathbf{x}) = P(\Theta_0 + \Theta_1 x_1 + \Theta_2 x_2)$$

rozhodovací hranice

Zvolme $\Theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$

(zatím neřešíme, jak
 Θ „nastavit“)



Model predikuje „ $y = 1$ “ $\Leftrightarrow -3 + x_1 + x_2 \geq 0$, čili když $x_1 + x_2 \geq 3$.

$$\Theta^T \mathbf{x}$$

Naopak když $x_1 + x_2 < 3$, model predikuje „ $y = 0$ “.

Pokud právě $x_1 + x_2 = 3 \Leftrightarrow h_{\Theta}(\mathbf{x}) = 0.5$



Rozhodovací hranice

Nelineární rozhodovací hranice

Volbou tvaru a parametrů hypotézy můžeme vytvářet libovolně složité rozhodovací hranice:


Zvolme $\Theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$

$$h_{\Theta}(\mathbf{x}) = P(\Theta_0 + \Theta_1 x_1 + \Theta_2 x_2 + \Theta_3 x_1^2 + \Theta_4 x_2^2)$$

Model predikuje „ $y = 1$ “ $\Leftrightarrow -1 + x_1^2 + x_2^2 \geq 0$

$$x_1^2 + x_2^2 \geq 1$$

(ne)rovnice kružnice





Cenová funkce logistické regrese

Odvození – výchozí podmínky

Trénovací množina o m vzorcích

$$T = \{(\mathbf{x}^{(1)}, y^{(1)}); (\mathbf{x}^{(2)}, y^{(2)}); \dots; (\mathbf{x}^{(m)}, y^{(m)})\}$$

$$\mathbf{x}^{(i)} = \begin{bmatrix} x_0^{(i)} \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix} \in \mathbb{R}^{n+1}, \forall i : x_0^{(i)} = 1; y \in \{0, 1\}$$

Hypotéza
$$h_{\Theta}(\mathbf{x}) = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$

Problém: Jak nastavit parametry Θ , aby algoritmus logistické regrese klasifikoval neznámé vzorky s nejmenší chybou?



Cenová funkce logistické regrese

Odvození


Lineární regrese – minimalizujeme cenovou funkci ve tvaru:

$$J(\Theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} \left(h_{\Theta}(\mathbf{x}^{(i)}) - y^{(i)} \right)^2$$

Logistická regrese – zavedeme funkci Cost:

$$J(\Theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost} \left(h_{\Theta}(\mathbf{x}^{(i)}), y^{(i)} \right)$$

$$\text{Cost} \left(h_{\Theta}(\mathbf{x}), y \right) = \frac{1}{2} \left(h_{\Theta}(\mathbf{x}) - y \right)^2$$



nekonvexní funkce
– GS nenalezne
glob. optimum

$$\frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$


Je třeba nadefinovat cenovou funkci jinak, aby GS fungoval...



Cenová funkce logistické regrese

Odvození

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\Theta}(\mathbf{x})) & \text{když } y = 1 \\ -\log(1 - h_{\Theta}(\mathbf{x})) & \text{když } y = 0 \end{cases}$$




max. penalizace v případě, že $h_{\Theta}(\mathbf{x}) = 0$, tj. $P(y = 1 | \mathbf{x}; \Theta) = 0$, ale přitom $y = 1$...



Cenová funkce logistické regrese

Odvození

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\Theta}(\mathbf{x})) & \text{když } y = 1 \\ -\log(1 - h_{\Theta}(\mathbf{x})) & \text{když } y = 0 \end{cases}$$



Když predikce $h_{\Theta}(\mathbf{x}) \rightarrow 1$,
pak $\text{Cost} \rightarrow \infty$

Je-li $y = 0$ a $h_{\Theta}(\mathbf{x}) = 0$, pak je
 Cost rovno nule (žádná pen-
nalizace)...



Cenová funkce logistické regrese

Zjednodušený zápis vhodný pro GS

Cenová funkce $J(\Theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\Theta}(\mathbf{x}^{(i)}), y^{(i)})$

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\Theta}(\mathbf{x})) & \text{když } y = 1 \\ -\log(1 - h_{\Theta}(\mathbf{x})) & \text{když } y = 0 \end{cases}$$

Příčemž vždy $y \in \{0; 1\}$ – to je významný poznatek, umožňující zjednodušit zápis cenové funkce:

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = -y \log(h_{\Theta}(\mathbf{x})) - (1 - y) \log(1 - h_{\Theta}(\mathbf{x}))$$

Pro $y = 1$: $\text{Cost}(h_{\Theta}(\mathbf{x}), y) = -\log(h_{\Theta}(\mathbf{x}))$

Pro $y = 0$: $\text{Cost}(h_{\Theta}(\mathbf{x}), y) = -\log(1 - h_{\Theta}(\mathbf{x}))$



Cenová funkce logistické regrese

Zjednodušený zápis vhodný pro GS

Cenová funkce

$$J(\Theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost} \left(h_{\Theta}(\mathbf{x}^{(i)}), y^{(i)} \right) =$$
$$= -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log(h_{\Theta}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\Theta}(\mathbf{x}^{(i)})) \right]$$

Tvar cenové funkce vychází z poznatků statistiky, z principů techniky zvané **metoda maximální věrohodnosti** (*Maximum Likelihood Estimation, MLE*):

- je **konvexní**

Odhad neznámých veličin z pozorovaných dat:

1. formulace pravděpodobnostního modelu,
2. ověření shody modelu s realitou.

Hledáme parametry Θ , tzn. **minimalizujeme** výše uvedenou cenovou funkci $J(\Theta)$...



Gradientní sestup v případě logistické regrese

Potřebujeme minimalizovat cenovou funkci $J(\Theta)$, abychom našli optimální nastavení parametrů $\Theta \rightarrow$ aplikujeme GS:

while not converged() do {

for j = 0 .. n do

$$\Theta_j \leftarrow \Theta_j - \alpha \frac{1}{m} \sum_{i=1}^m \left(h_{\Theta}(\mathbf{x}^{(i)}) - y^{(i)} \right) \cdot x_j^{(i)}$$

}

$$h_{\Theta}(\mathbf{x}) = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$

Algoritmus vypadá stejně (a taky **stejný je**) jako v případě lineární regrese, až na tvar hypotézy $h_{\Theta}(\mathbf{x})$...



Pokročilejší optimalizační algoritmy pro výpočet parametrů logistické regrese

GS je tzv. „baseline“ – základní, nejméně sofistikovaná podoba optimalizačního algoritmu (viz přednáška Lineární regrese – asymptotická míra konvergence).

Ovšem implementujeme-li GS, musíme naprogramovat výpočet **cenové funkce** $J(\Theta)$ – pro potřeby sledování konvergence, a její **parciální derivace** – pro potřeby výpočtu kroku GS...

Toto lze využít při aplikaci pokročilejších algoritmů:

- **Konjugovaný GS** (*Conjugate GD*)
- **BFGS** (*Broyden-Fletcher-Goldfarb-Shanno*)
- **L-BFGS** (*Limited-memory BFGS*)

} **značně
komplikované**

Výhody: mnohem rychlejší konvergence, není třeba volit α



Pokročilejší optimalizační algoritmy

Implementace

Není příliš rozumné implementovat pokročilejší optimalizační algoritmy (CGD, BFGS, L-BFGS) vlastními silami – existuje řada **knihoven** (JProGraM, netlib, SciPy, HANSO, ...)

V **MATLABu/Octave**:

- funkce FMINUNC (Function Minimisation Unconstrained)
– „nadopovaný“ gradientní sestup

UKÁZKA





Klasifikace pomocí LogR do více tříd

Algoritmus „One vs All“

Klasifikace do více tříd (*Multiclass Classification*) –

Predikce počasí: jasno, polojasno, zataženo, déšť, sněžení

Učitel: $y = 1$ $y = 2$ $y = 3$ $y = 4$ $y = 5$

Lékařská diagnóza: zdrav(a), rýma, kašel, zácpa, smrt


Klasifikace článků: zprávy, kultura, sport, věda, politika






One vs All (One vs Rest)



Algoritmus klasifikace do více tříd



Převědeme multi-class problém na 3 binární problémy




Třída 1: 
 Třída 2: 
 Třída 3: 





One vs All (One vs Rest)

Algoritmus klasifikace do více tříd



Obecně $h_{\Theta}^{(i)}(\mathbf{x}) = P(y = i | \mathbf{x}; \Theta)$, pro $i \in \{1, 2, 3\}$

Tj. natrénujeme i binárních logistických regresních klasifikátorů pro každou třídu i tak, aby predikovaly pravděpodobnost příslušnosti vzorku k i -té třídě.

Při klasifikaci neznámého vzorku vybíráme cílovou třídu i tak, aby $\max_i h_{\Theta}^{(i)}(\mathbf{x})$