



Strojové učení

5 Logistická regrese

- Logistická regrese
- Model hypotézy pro LogR
- Interpretace výsledků
- Rozhodovací hranice
- Cenová funkce pro LogR
- Klasifikace do více tříd
- Algoritmus One vs All





Logistická regrese

Regrese pro predikci diskretních hodnot

- predikovaná proměnná $y = h_{\odot}(\mathbf{x})$ nabývá diskretních hodnot
bud' 0 nebo 1 – **binomická** či **binární logistická regrese**
nebo 0 až K – **multinomická logistická regrese**
také logistická regrese s vícekategoriální vysvětlující proměnnou, **tj. jedná se o klasifikační úlohu**
- predikovaná proměnná (čili modelovaná veličina) má **alternativní rozdělení p-sti** (*Bernoulli Distribution*)
variantu binomického rozdělení $Bi(n, p)$, kde $n = 1$ a p je p-st úspěchu (čili proměnná nabývá hodnot 0 nebo 1)
- **jeden z nejpopulárnějších a nejrozšířenějších algoritmů**, řada dalších technik z oblasti strojového učení je na ní založena





Logistická regrese

Příklady klasifikačních úloh

Binární logistická regrese –

$$y = h_{\theta}(\mathbf{x}) \in \{0; 1\}$$

→ 0: negativní třída

→ 1: pozitivní třída

- E-mail: spam / ne-spam
- Lékařská diagnostika nádorů: zhoubný / nezhoubný
- Bezpečnost (IS): autentizovaný / neautentizovaný

n -ární (multinomická) lineární regrese –

$$y = h_{\theta}(\mathbf{x}) \in \mathbf{N} \cup \{0\}$$

- Lékařská diagnostika: angína / chřipka / rýma
např. existující systém DXplain (<http://dxplain.org/>)




Logistická regrese

Motivační příklad – tribodiagnostika

Vyměnit součástku?

ANO

NE



Co se stane při aplikaci již známého aparátu lineární regrese?
Zkusme proložit data přímkou, tj. hypotéza h_{θ}



Logistická regrese


Motivační příklad – tribodiagnostika

Problém: Hypotéza v tomto tvaru předpovídá hodnoty mimo $\langle 0, 1 \rangle$

Vyměnit součástku?

ANO

NE



Klasifikaci provedeme prahováním hypotézy h_θ
 pro $h_\theta(x) \geq 0.5$: $y \leftarrow 1$; pro $h_\theta(x) < 0.5$: $y \leftarrow 0$



Logistická regrese

Motivační příklad – tribodiagnostika


Můžeme mít štěstí a bude to nějak fungovat, a častěji to **fungovat nebude**, a to zejména proto

- byt jsou data (odpovědi učitele) v trénovací množině z množiny $\{0; 1\}$, algoritmus předpovídá spočítá hodnotu v intervalu $(-\infty; \infty) \rightarrow$ nevíme, co dělat s hodnotou mimo interval $\langle 0; 1 \rangle \dots$
- pro hodnoty $h_{\theta}(x) \in \langle 0; 1 \rangle$ stanovíme práh τ – to ale nemusí být správná hodnota prahu, která oddělující nadplocha neseparuje data z trénovací množiny správně podle pokynů učitele
- vyskytnou-li se v datech extrémní marginální případy, takto navržený mechanismus klasifikace selže (viz následující obr.)



Logistická regrese

Motivační příklad – tribodiagnostika





Logistická regrese

Vlastnosti

Klasifikační úloha: $y \in \{0; 1\}$

Lineární regrese: $y = h_{\theta}(x) \in (-\infty; \infty)$

- omezení hypotézy na interval $<0; 1>$ je problémem, protože není jednoznačné, nelze algoritmem LR určit, jaká je velmi citlivé na extrémní marginální hodnoty množině, atd.

Logistická regrese: $y = h_{\theta}(x) \in <0; 1>$

- ač se to z historických důvodů nazývá regrese, jde o **klasifikaci** (protože hypotéza logistické regrese je pravděpodobnost, že $y =$





Logistická regrese

Reprezentace hypotézy


Požadujeme $0 \leq h_{\Theta}(\mathbf{x}) \leq 1$,

tj. $h_{\Theta}(\mathbf{x}) = P(\Theta^T \mathbf{x})$

reálné
číslo

Hypotéza má tedy tvar:

$$h_{\Theta}(\mathbf{x}) = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$



– **sigmoida** je speciálním případem tzv. **logistického** (Logistic Function) pro $a = 1, m = 0, n = 1, \tau = 1$

$$f(t; a, m, n, \tau) = a \frac{1 + m e^{-t}}{1 + n e^{-t}}$$



Logistická regrese

Interpretace výsledků hypotézy

$h_{\Theta}(\mathbf{x})$ – odhad **pravděpodobnosti**, že modelová
bude hodnoty 1 (tj. např. jev nastane),
vektor příznaků $\mathbf{x}$

Příklad: Při tribodiagnostice byla naměřena pr
částic kovu v oleji 3.27 μ – tzn. vstupem hypot

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ 3.27 \end{bmatrix}$$

nutné, aby to
maticově jak

$$h_{\Theta}(\mathbf{x}) = \frac{1}{1 + e^{-(\Theta_0 + \Theta_1 \cdot 3.27)}} = 0.79$$

Hypotéza říká, že při velikosti částic 3.27 μ je s
ností 79% potřeba ložisko vyměnit.



Logistická regrese

Statistická interpretace výsledků h

$h_{\Theta}(\mathbf{x})$ – pravděpodobnost, že $y = 1$ za podmínk
zovaná Θ :

$$h_{\Theta}(\mathbf{x}) = P(y = 1 \mid \mathbf{x}; \Theta)$$

Z toho plynou některé zřejmé závěry:

$P(y = 0 \mid \mathbf{x}; \Theta) + P(y = 1 \mid \mathbf{x}; \Theta) = 1$, z čehož

$P(y = 0 \mid \mathbf{x}; \Theta) = 1 - P(y = 1 \mid \mathbf{x}; \Theta)$

Tzn. v předchozím příkladu odhad pravděpodob
ko není třeba měnit, je $1 - 0.79 = 0.21$, tj. 21%



Logistická regrese

Chování modelu

Hypotéza $h_{\Theta}(\mathbf{x}) = P(\Theta^T \mathbf{x})$, kde

$$P(t) = \frac{1}{1 + e^{-t}}$$

Model predikuje:

„ $y = 1$ “ $\Leftrightarrow h_{\Theta}(\mathbf{x}) \geq 0.5$, tj.


$$P(t) \geq 0.5$$

$$\Theta^T \mathbf{x} \geq 0$$

„ $y = 0$ “ $\Leftrightarrow h_{\Theta}(\mathbf{x}) < 0.5$, tj.

$$P(t) < 0.5$$

$$\Theta^T \mathbf{x} < 0$$






Rozhodovací hranice (Decision Boundary) Chování LR v obrazovém prostoru

$$h_{\Theta}(\mathbf{x}) = P(\Theta_0 + \Theta_1 x_1 + \Theta_2 x_2)$$

rozhodovací hranice

Zvolme $\Theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$

(zatím neřešíme, jak Θ „nastavit“)



Model predikuje „ $y = 1$ “ $\Leftrightarrow -3 + x_1 + x_2 \geq 0$, čili $\Theta^T \mathbf{x}$


Naopak když $x_1 + x_2 < 3$, model predikuje „ $y = 0$ “
Pokud právě $x_1 + x_2 = 3 \Leftrightarrow h_{\Theta}(\mathbf{x}) = 0.5$



Rozhodovací hranice

Nelineární rozhodovací hranice

Volbou tvaru a parametrů hypotézy můžeme vytvářet libovolně složité rozhodovací hranice:



Zvolme $\Theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$

$$h_{\Theta}(\mathbf{x}) = P(\Theta_0 + \Theta_1 x_1 + \Theta_2 x_2 + \Theta_3 x_1^2 + \Theta_4 x_2^2)$$

Model predikuje „ $y = 1$ “ $\Leftrightarrow -1 + x_1^2 + x_2^2 \geq 0$

$$x_1^2 + x_2^2 \geq 1$$

(n



Cenová funkce logistické regrese

Odvození – výchozí podmínky

Trénovací množina o m vzorcích

$$T = \{(\mathbf{x}^{(1)}, y^{(1)}); (\mathbf{x}^{(2)}, y^{(2)}); \dots; (\mathbf{x}^{(m)}, y^{(m)})\}$$

$$\mathbf{x}^{(i)} = \begin{bmatrix} x_0^{(i)} \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix} \in \mathbb{R}^{n+1}, \forall i : x_0^{(i)} = 1; y^{(i)} \in \{0, 1\}$$

Hypotéza
$$h_{\Theta}(\mathbf{x}) = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$

Problém: Jak nastavit parametry Θ , aby algoritmus logistické regrese klasifikoval neznámé vzorky s minimální chybou?



Cenová funkce logistické regrese Odvození

Lineární regrese – minimalizujeme cenovou funkci


$$J(\Theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} \left(h_{\Theta}(\mathbf{x}^{(i)}) - y^{(i)} \right)^2$$

Logistická regrese – zavedeme funkci Cost:

$$J(\Theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}\left(h_{\Theta}(\mathbf{x}^{(i)}), y^{(i)}\right)$$

↓
↓

$\text{Cost}(h_{\Theta}(\mathbf{x}), y)$




**nekonvexní funkce
– GS nenalezne
glob. optimum**

**Je třeba nadefinovat
funkci jinak, aby GS**



Cenová funkce logistické regrese Odvození

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\Theta}(\mathbf{x})) \\ -\log(1 - h_{\Theta}(\mathbf{x})) \end{cases}$$




ma
pac
P(y
přít



Cenová funkce logistické regrese

Odvození

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\Theta}(\mathbf{x})) \\ -\log(1 - h_{\Theta}(\mathbf{x})) \end{cases}$$





Cenová funkce logistické regrese

Zjednodušený zápis vhodný pro GS

Cenová funkce $J(\Theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\Theta}(\mathbf{x}_i), y_i)$

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\Theta}(\mathbf{x})) & \text{if } y = 1 \\ -\log(1 - h_{\Theta}(\mathbf{x})) & \text{if } y = 0 \end{cases}$$

Přičemž vždy $y \in \{0; 1\}$ – to je významný poznámka, která zjednoduší zápis cenové funkce:

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = -y \log(h_{\Theta}(\mathbf{x})) - (1 - y) \log(1 - h_{\Theta}(\mathbf{x}))$$

Pro $y = 1$: $\text{Cost}(h_{\Theta}(\mathbf{x}), y) = -\log(h_{\Theta}(\mathbf{x}))$

Pro $y = 0$: $\text{Cost}(h_{\Theta}(\mathbf{x}), y) = -\log(1 - h_{\Theta}(\mathbf{x}))$



Cenová funkce logistické regrese

Zjednodušený zápis vhodný pro GS

Cenová funkce

$$J(\Theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\Theta}(\mathbf{x}^{(i)}))$$

$$= -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log(h_{\Theta}(\mathbf{x}^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\Theta}(\mathbf{x}^{(i)})) \right]$$

Tvar cenové funkce vychází z poznatků statistické
techniky zvané **metoda maximální věrohodnosti**
(*Likelihood Estimation, MLE*):

- je **konvexní**

Odhad neznámých veličin
1. formulace pravděpodobnosti
2. ověření shody modelu

Hledáme parametry Θ , tzn. **minimalizujeme** v
cenovou funkci $J(\Theta)$...



Gradientní sestup v případě logistické regrese

Potřebujeme minimalizovat cenovou funkci $J(\Theta)$ a najít optimální nastavení parametrů $\Theta \rightarrow$ aplikaci

while not converged() do {

for j = 0 .. n do

$$\Theta_j \leftarrow \Theta_j - \alpha \frac{1}{m} \sum_{i=1}^m \left(h_{\Theta}(\mathbf{x}^{(i)}) - y^{(i)} \right)$$

}

$h_{\Theta}(\mathbf{x})$

Algoritmus vypadá stejně (a taky **stejný je**) jako pro lineární regrese, až na tvar hypotézy $h_{\Theta}(\mathbf{x})$...



Pokročilejší optimalizační algoritmy pro výpočet parametrů logistické

GS je tzv. „baseline” – základní, nejméně sofistikovaný optimalizační algoritmus (viz přednáška Lineární asymptotická míra konvergence).

Ovšem implementujeme-li GS, musíme naprogramovat výpočet **cenové funkce** $J(\Theta)$ – pro potřeby sledování a její **parciální derivace** – pro potřeby výpočtu

Toto lze využít při aplikaci pokročilejších algoritmů

- **Konjugovaný GS** (*Conjugate GD*)
- **BFGS** (*Broyden-Fletcher-Goldfarb-Shanno*)
- **L-BFGS** (*Limited-memory BFGS*)

Výhody: mnohem rychlejší konvergence, není



Pokročilejší optimalizační algoritmy Implementace

Není příliš rozumné implementovat pokročilejší algoritmy (CGD, BFGS, L-BFGS) vlastními silami. Použijte knihovny (JProGraM, netlib, SciPy, HANSO, ...)

V **MATLABu/Octave**:

- funkce FMINUNC (Function Minimisation Unction)
– „nadopovaný“ gradientní sestup

UKÁZKA





Klasifikace pomocí LogR do více tříd Algoritmus „One vs All”

Klasifikace do více tříd (*Multiclass Classification*)

Predikce počasí: jasno, polojasno, zataženo, d


Učitel: $y = 1$ $y = 2$ $y = 3$ $y =$

Lékařská diagnóza: zdrav(a), rýma, kašel, zácpa

Klasifikace článků: zprávy, kultura, sport, věda

binární
umíme


multiclass





One vs All (One vs Rest)

Algoritmus klasifikace do více tříd





Převédeme multi-class problém na 3 binární problémy

Třída 1:

Třída 2:


Třída 3:





One vs All (One vs Rest)

Algoritmus klasifikace do více tříd



Obecně $h_{\Theta}^{(i)}(\mathbf{x}) = P(y = i | \mathbf{x}; \Theta)$, pro $i \in \{1, \dots, K\}$

Tj. natrénujeme i binárních logistických regresí
rů pro každou třídu i tak, aby predikovaly prav
slušnost vzorku k i -té třídě.

Při klasifikaci neznámého vzorku vybíráme cíl
aby $\max_i h_{\Theta}^{(i)}(\mathbf{x})$